

# Aplicación de Autocorrelación Espacial

Curso: Estadística Espacial

Estudiante: Willy Vilca Apaza

Universidad Nacional del Altiplano – Puno

---

Fecha de inicio: 03/10/2025

Hora: 15:14

Fecha de cierre: 07/10/2025

Hora: 15:00

## Enunciado de la tarea

Realizar un resumen de los artículos y su convergencia, con la autocorrelación espacial.

## 1. Resumen Académico: Autocorrelación Espacial en Estudios Costeros

**Análisis de Convergencia Metodológica en Investigaciones de Vulnerabilidad Costera**

### Introducción

La autocorrelación espacial representa un concepto fundamental en el análisis geoespacial que cuantifica el grado de similitud entre valores de una variable en ubicaciones geográficas adyacentes. Este documento examina la convergencia metodológica de tres investigaciones que emplean técnicas de autocorrelación espacial para evaluar fenómenos costeros relacionados con el cambio climático y la elevación del nivel del mar.

### Artículo 1: Evaluación de la Exposición Costera al Aumento del Nivel del Mar

**Referencia:** Lamhadri, S., Senechal, N., Ouallali, A., El Hafyani, M., Chahid, D., & Benhachmi, M. K. (2025). *Evaluación de la exposición costera al aumento del nivel del mar: un enfoque combinado de modelado cualitativo y análisis de autocorrelación espacial*. *Natural Hazard Research*.

## Contexto y Objetivos

El estudio se desarrolla en la costa atlántica de Marruecos, específicamente en la región de Salé, con un tramo de 25 km de litoral. Evalúa la exposición costera a los riesgos derivados del aumento del nivel del mar mediante la integración del modelo InVEST con técnicas de autocorrelación espacial.

## Metodología de Autocorrelación Espacial

El análisis combina dos escalas:

- **Análisis Global:** Utiliza el Índice de Moran Global para cuantificar el grado general de agrupamiento espacial del Índice de Exposición (IE). Los valores obtenidos (0.70–0.80) indican una fuerte autocorrelación positiva.
- **Análisis Local:** Usa los Indicadores Locales de Asociación Espacial (LISA) para identificar patrones específicos de agrupamiento tipo Alto–Alto (H–H) y Bajo–Bajo (L–L).

## Hallazgos Principales

Los resultados demuestran que la distribución del índice de exposición no es aleatoria, sino dependiente de factores geomorfológicos. El Índice de Moran fue estadísticamente significativo ( $p < 0.001$ ), con valores  $Z$  mayores a 19.

## Aplicación

La autocorrelación espacial permitió identificar zonas costeras críticas y apoyar decisiones de planificación y mitigación del riesgo.

## 2. Artículo 2: Autocorrelación Espacial en el Análisis de la Vegetación – Montañas Yinshan, China

El artículo “*Evidencia por teledetección sobre la heterogeneidad espaciotemporal de la evolución de la vegetación en las montañas Yinshan, China*”, publicado en *Ecological Indicators* (2025), analiza la dinámica espacio-temporal de la vegetación en una zona ecológicamente vulnerable del norte de China.

Se emplean datos NDVI (1984–2022) y técnicas como Theil–Sen, Mann–Kendall, índice de Hurst y autocorrelación espacial bivariada. Esta última cuantifica la dependencia espacial entre el crecimiento de la vegetación y variables climáticas (temperatura y precipitación).

El Moran's I entre NDVI y precipitación fue 0.88 ( $p < 0.01$ ), indicando correlación positiva; con la temperatura fue negativa ( $-0.46$ ). El índice de Hurst ( $H = 0.47$ ) reflejó tendencia anti-persistente. La precipitación resultó ser el principal factor determinante del crecimiento vegetal.

### 3. Artículo 3: Heterogeneidad Espacial Estratificada de la Incidencia de Paperas en China

El artículo "*Heterogeneidad espacial estratificada de la incidencia de paperas en China: un análisis basado en Geodetector*", publicado en *Frontiers in Public Health* (2025), explora los patrones espaciales de la incidencia de paperas y los factores asociados.

El índice Moran's I = 0.399 ( $p < 0.001$ ) mostró fuerte autocorrelación positiva. El análisis identificó como factores más influyentes el ratio de dependencia infantil ( $PD = 0.54$ ) y la tasa de analfabetismo ( $PD = 0.49$ ). Las interacciones PIB–analfabetismo alcanzaron  $PD = 0.88$ . Las provincias occidentales registraron mayor incidencia.

## Conclusión General

Los tres estudios evidencian la relevancia de la autocorrelación espacial como herramienta para detectar patrones geográficos no aleatorios. Su aplicación en contextos diversos (costero, ecológico y epidemiológico) confirma su versatilidad para la gestión ambiental, la planificación territorial y la salud pública.

### Código 1: Autocorrelación espacial global de incidencia de paperas en China

```
1 library(spdep)
2 library(rgdal)
3
4 china <- readOGR("china_provinces.shp")
5 mumps <- read.csv("mumps_incidence.csv")
6 china@data <- merge(china@data, mumps, by = "province")
7
8 vecinos <- poly2nb(china)
```

```

9 pesos <- nb2listw(vecinos, style = "W")
10
11 moran_result <- moran.test(china@data$incidence, listw = pesos)
12 print(moran_result)
13
14 lisa <- localmoran(china@data$incidence, listw = pesos)
15 china@data$lisa_cluster <- factor(ifelse(lisa[,1] > 0, "High-High",
16   "Low-Low"))
17
18 spplot(china, "lisa_cluster", main = "Clusters locales de
19   incidencia de paperas (LISA)")

```

Listing 1: Autocorrelación espacial global de incidencia de paperas en China

## Código 2: Análisis de autocorrelación espacial – Evaluación de exposición costera

```

1
2 library(spdep)      # Análisis de autocorrelación espacial
3 library(sf)         # Manejo de datos espaciales
4 library(ggplot2)    # Visualización
5 library(viridis)    # Paletas de colores
6
7 # -----
8 # 1. CARGA Y PREPARACIÓN DE DATOS
9 # -----
10
11 # Cargar datos espaciales de la línea costera
12 # (Asumiendo que tiene coordenadas y valores de índice de
13   Exposición)
14
15 costa_data <- st_read("ruta/a/sus/datos/costeros.shp")
16
17 # Verificar estructura de datos
18 head(costa_data)
19 summary(costa_data$exposure_index)
20
21 # -----
22 # 2. CREAR MATRIZ DE VECINDAD ESPACIAL
23 # -----
24
25 # Definir vecinos basados en distancia (por ejemplo, 500 metros)

```

```

24 coords <- st_coordinates(st_centroid(costa_data))
25 nb_dist <- dnearneigh(coords, 0, 500) # vecinos dentro de 500m
26
27 # Alternativamente, usar k vecinos m s cercanos
28 # nb_knn <- knn2nb(knearneigh(coords, k = 5))
29
30 # Convertir a lista de pesos espaciales
31 lw <- nb2listw(nb_dist, style = "W", zero.policy = TRUE)
32
33 # Visualizar estructura de vecindad
34 plot(st_geometry(costa_data), border = "gray")
35 plot(nb_dist, coords, add = TRUE, col = "red", pch = 19)
36 title("Estructura de Vecindad Espacial")
37
38 # -----
39 # 3. AN LISIS GLOBAL: NDICE DE MORAN
40 # -----
41
42 # Calcular ndice de Moran Global
43 moran_global <- moran.test(costa_data$exposure_index,
44                             lw,
45                             randomisation = TRUE)
46
47 # Mostrar resultados
48 print("=== NDICE DE MORAN GLOBAL ===")
49 print(paste("Estadístico I de Moran:", round(moran_global$estimate
50 [1], 4)))
51 print(paste("Valor esperado:", round(moran_global$estimate[2], 4)))
52 print(paste("Varianza:", round(moran_global$estimate[3], 6)))
53 print(paste("Valor p:", format.pval(moran_global$p.value, digits =
54 4)))
55 print(paste("Estadístico Z:", round(moran_global$statistic, 4)))
56
57 # Interpretación automática
58 if(moran_global$p.value < 0.01 & moran_global$estimate[1] > 0) {
59   print("INTERPRETACIÓN: Existe autocorrelación espacial positiva
60   significativa")
61   print("Los valores similares tienden a agruparse espacialmente")
62 } else if(moran_global$p.value < 0.01 & moran_global$estimate[1] <
63 0) {
64   print("INTERPRETACIÓN: Existe autocorrelación espacial negativa
65   significativa")
66 } else {

```

```

62   print("INTERPRETACION: No hay evidencia de autocorrelación
      espacial significativa")
63 }
64
65 # Prueba de Monte Carlo para robustez (999 permutaciones)
66 moran_mc <- moran.mc(costa_data$exposure_index,
67                      lw,
68                      nsim = 999)
69
70 print("=== PRUEBA DE MONTE CARLO ===")
71 print(moran_mc)
72
73 # Gráfico de la distribución de Monte Carlo
74 plot(moran_mc, main = "Simulación Monte Carlo del índice de Moran
      ")
75
76 # -----
77 # 4. ANALISIS LOCAL: LISA
78 # -----
79
80 # Calcular índice de Moran Local
81 lisa <- localmoran(costa_data$exposure_index, lw)
82
83 # Agregar resultados LISA al dataframe
84 costa_data$lisa_I <- lisa[, 1]          # Estadístico local
85 costa_data$lisa_pval <- lisa[, 5]      # Valor p
86
87 # Clasificar en categorías LISA significativas (p < 0.05)
88 costa_data$lisa_cat <- "No Significativo"
89
90 # Calcular media y desviación de los valores
91 mean_exp <- mean(costa_data$exposure_index)
92 costa_data$exp_std <- scale(costa_data$exposure_index)
93
94 # Calcular lag espacial estandarizado
95 costa_data$lag_std <- scale(lag.listw(lw, costa_data$exposure_index
    ))
96
97 # Categorizar según cuadrantes
98 costa_data$lisa_cat[costa_data$lisa_pval < 0.05 &
99                    costa_data$exp_std > 0 &
100                    costa_data$lag_std > 0] <- "High-High"
101

```

```

102 costa_data$lisa_cat[costa_data$lisa_pval < 0.05 &
103                      costa_data$exp_std < 0 &
104                      costa_data$lag_std < 0] <- "Low-Low"
105
106 costa_data$lisa_cat[costa_data$lisa_pval < 0.05 &
107                      costa_data$exp_std > 0 &
108                      costa_data$lag_std < 0] <- "High-Low"
109
110 costa_data$lisa_cat[costa_data$lisa_pval < 0.05 &
111                      costa_data$exp_std < 0 &
112                      costa_data$lag_std > 0] <- "Low-High"
113
114 # Resumen de conglomerados LISA
115 print("=== RESUMEN DE CONGLOMERADOS LISA ===")
116 table(costa_data$lisa_cat)
117 prop.table(table(costa_data$lisa_cat)) * 100
118
119 # -----
120 # 5. VISUALIZACION DE RESULTADOS
121 # -----
122
123 # Mapa de conglomerados LISA
124 ggplot(costa_data) +
125   geom_sf(aes(fill = lisa_cat), color = "black", size = 0.3) +
126   scale_fill_manual(
127     values = c("High-High" = "#d7191c",
128               "Low-Low" = "#2b83ba",
129               "High-Low" = "#fdae61",
130               "Low-High" = "#abd9e9",
131               "No Significativo" = "gray90"),
132     name = "Tipo de Conglomerado"
133   ) +
134   theme_minimal() +
135   labs(title = "Mapa de Conglomerados LISA",
136        subtitle = "Análisis de Autocorrelación Espacial Local",
137        caption = "Nivel de significancia: p < 0.05") +
138   theme(legend.position = "bottom")
139
140 # Mapa del índice de Exposición
141 ggplot(costa_data) +
142   geom_sf(aes(fill = exposure_index), color = "black", size = 0.3)
143   +
144   scale_fill_viridis(option = "plasma",

```

```

144         name = " ndice de\nExposici n") +
145 theme_minimal() +
146 labs(title = "Distribuci n Espacial del ndice de Exposici n
147         Costera")
148 # Diagrama de dispersi n de Moran
149 moran_plot <- moran.plot(costa_data$exposure_index,
150         lw,
151         labels = FALSE,
152         xlab = " ndice de Exposici n (
153         estandarizado)",
154         ylab = "Lag Espacial",
155         main = "Diagrama de Dispersi n de Moran")
156 # -----
157 # 6. AN LISIS POR ESCENARIOS
158 # -----
159
160 # Funci n para analizar m ltiples escenarios
161 analizar_escenario <- function(data, variable, nombre_escenario) {
162
163     # ndice de Moran Global
164     moran <- moran.test(data[[variable]], lw, randomisation = TRUE)
165
166     # LISA
167     lisa <- localmoran(data[[variable]], lw)
168     data$lisa_pval <- lisa[, 5]
169
170     # Clasificar conglomerados
171     data$exp_std <- scale(data[[variable]])
172     data$lag_std <- scale(lag.listw(lw, data[[variable]]))
173
174     data$cluster <- "NS"
175     data$cluster[data$lisa_pval < 0.05 & data$exp_std > 0 & data$lag_
176         std > 0] <- "HH"
177     data$cluster[data$lisa_pval < 0.05 & data$exp_std < 0 & data$lag_
178         std < 0] <- "LL"
179     data$cluster[data$lisa_pval < 0.05 & data$exp_std > 0 & data$lag_
180         std < 0] <- "HL"
181     data$cluster[data$lisa_pval < 0.05 & data$exp_std < 0 & data$lag_
182         std > 0] <- "LH"
183
184     # Resultados

```



```

181 resultados <- list(
182   escenario = nombre_escenario,
183   moran_I = moran$estimate[1],
184   moran_p = moran$p.value,
185   moran_z = moran$statistic,
186   clusters = table(data$cluster),
187   clusters_pct = prop.table(table(data$cluster)) * 100
188 )
189
190 return(resultados)
191 }
192
193 # Ejemplo de uso para mltiples escenarios
194 # escenario1 <- analizar_escenario(costa_data, "exposure_index", "
195   Escenario 1")
196 # escenario2 <- analizar_escenario(costa_data, "exposure_scenario2
197   ", "Escenario 2")
198
199 # -----
200 # 7. EXPORTAR RESULTADOS
201 # -----
202
203 # Guardar mapa de conglomerados
204 st_write(costa_data, "resultados_lisa_clusters.shp", delete_layer =
205   TRUE)
206
207 # Guardar tabla de resultados
208 resultados_tabla <- data.frame(
209   Metrica = c(" ndice de Moran", "Valor Z", "Valor p"),
210   Valor = c(
211     round(moran_global$estimate[1], 4),
212     round(moran_global$statistic, 4),
213     format.pval(moran_global$p.value, digits = 4)
214   )
215 )
216
217 write.csv(resultados_tabla, "resultados_moran_global.csv", row.
218   names = FALSE)
219
220 # Resumen de conglomerados
221 resumen_clusters <- as.data.frame(table(costa_data$lisa_cat))
222 names(resumen_clusters) <- c("Tipo_Conglomerado", "Frecuencia")
223 resumen_clusters$Porcentaje <- round(resumen_clusters$Frecuencia /

```

```
220         sum(resumen_clusters$
              Frecuencia) * 100, 2)
221
222 write.csv(resumen_clusters, "resumen_clusters_lisa.csv", row.names
           = FALSE)
223
224 print("=== AN LISIS COMPLETADO ===")
225 print("Los resultados han sido guardados en el directorio de
       trabajo")
```

Listing 2: Análisis de autocorrelación espacial de exposición costera

### Código 3: Autocorrelación espacial bivariada (NDVI y precipitación)

```
1 library(spdep)
2 library(raster)
3
4 ndvi <- raster("NDVI_Yinshan.tif")
5 prec <- raster("Precip_Yinshan.tif")
6
7 coords <- coordinates(ndvi)
8 vecinos <- knn2nb(knearneigh(coords, k = 4))
9 pesos <- nb2listw(vecinos, style = "W")
10
11 ndvi_val <- getValues(ndvi)
12 prec_val <- getValues(prec)
13 moran_bi <- moran(ndvi_val, prec_val, listw = pesos, n = length(
    ndvi_val))
14
15 print(moran_bi)
```

Listing 3: Cálculo de autocorrelación espacial bivariada en R